

1. Equipo y título de trabajo

Título de trabajo: La forma del día: cómo cambió el ritmo horario del metro de Nueva York, 2020-2024.

Integrantes: Renzo Acervo Correa, Stewart Maquera Bobadilla, José Condori Palomino.

Repositorio: <https://github.com/stewartmb/data-visualization-2026-2>

2. Problema y contexto

El metro de Nueva York programa su servicio alrededor del doble pico del día laborable: una cresta en la mañana y otra al final de la tarde. Sobre esa forma se decide la frecuencia de trenes y la asignación de personal.

Entre 2020 y 2024 esa forma cambió. El problema es que casi siempre se reporta como un solo número: cuánto se recuperó el ridership frente al nivel previo. Ese número dice cuánta demanda volvió, pero no dice a qué hora vuelve ni en qué estaciones. Son cosas distintas. Una estación puede haber recuperado el 90% de sus entradas y aun así haber perdido su pico de la mañana. Importa porque si el perfil de demanda de un grupo de estaciones cambió y la programación siguió igual, hay trenes de más en unas franjas y de menos en otras.

Por eso no vamos a trabajar con el volumen total sino con el perfil horario semanal de cada estación: 24 horas por 7 días, o sea 168 valores por estación. Ese vector describe el ritmo de la estación, no su tamaño. Comparándolo entre estaciones y entre años se puede ver qué cambió y dónde.

Esto necesita una visualización y no una tabla. Son más de 400 estaciones, cada una con 168 valores por año, y la pregunta es de comparación de formas: qué perfiles se parecen entre sí, cuáles cambiaron y si esos cambios se agrupan en el mapa. Un listado numérico de ese tamaño no permite ver parecidos ni detectar el patrón geográfico; codificar el perfil visualmente y enlazarlo con un mapa sí.

Contexto mínimo para entender los datos: el metro opera 24 horas, tiene más de 400 complejos de estación en cinco boroughs, y durante el período convivieron dos sistemas de pago, MetroCard y OMNY, en plena transición.

3. Audiencia y propósito

La audiencia principal son planificadores de servicio de la MTA y analistas de transporte urbano. La visualización debe ayudarlos a decidir dónde reasignar frecuencia, permitiéndoles identificar qué estaciones cambiaron su perfil de demanda, en qué dirección y si hay algún patrón geográfico.

Un uso concreto sería este: un planificador filtra las estaciones cuyo pico matutino cayó más que su pico de la tarde, las ve resaltadas sobre el mapa, y compara ese conjunto con la frecuencia programada en esa franja.

Como audiencia secundaria vemos a periodistas de transporte y gobiernos locales. A ellos la visualización debe ayudarlos a entender si la recuperación fue pareja entre barrios y quiénes siguieron usando el sistema en los años más bajos.

4. Dataset

Fuente. MTA Subway Hourly Ridership: 2020-2024, publicado por la Metropolitan Transportation Authority en el portal Open NY del Estado de Nueva York. Identificador Socrata `wujg-7c2s`. Son 120,855,568 registros con granularidad horaria, de 2020 a 2024, para los cinco boroughs y tres modos: metro, Staten Island Railway y el tranvía de Roosevelt Island.

Colector y método de recolección. La MTA registra las entradas al sistema en los torniquetes: swipes de MetroCard y taps de OMNY, estos últimos provistos por Cubic. Antes de publicar limpia y deduplica las transacciones y saca las de agencias asociadas. Son estimaciones, no un conteo exacto; la MTA declara que quedan dentro del 1% de las cifras que reporta públicamente.

Atributos relevantes. `transit_timestamp` para el eje temporal; `station_complex_id` y `station_complex` como unidad de análisis; `borough`, `latitude` y `longitude` para lo espacial; `ridership` como medida principal; `payment_method` y `fare_class_category` para desagregar.

Problemas de calidad. Corrimos 33 controles sobre la muestra de trabajo, documentados en el repositorio. No salieron valores faltantes, duplicados en la clave compuesta, valores negativos, casos donde `transfers` supere a `ridership`, ni coordenadas fuera del rango de Nueva York. Los problemas que sí encontramos son estructurales:

- Son entradas, no salidas. No hay pares origen-destino, así que no podemos analizar flujos de viaje con esta fuente.
- `transfers` es un subconjunto de `ridership`, no una medida aparte. Sumarlas duplicaría el conteo.
- La granularidad es de complejo, no de estación individual. Un complejo puede agrupar varias estaciones conectadas.
- El histórico puede cambiar por transacciones tardías.
- La transición de MetroCard a OMNY complica comparar por método de pago a lo largo del tiempo. Una caída en MetroCard no es una caída de demanda, es migración.

Condiciones de acceso. Datos abiertos, sin registro. La ficha oficial no declara una licencia específica; el documento metodológico de la MTA dice que no hay limitaciones de uso, y además aplican los términos de OPEN-NY. Atribuimos a MTA y Open NY.

Preprocesamiento esperado. El archivo completo pesa varios gigabytes, así que no se puede descargar entero ni servir al navegador.

Vamos a agregar del lado del servidor con consultas SoQL contra la API de Socrata y bajar tres tablas de pocos megabytes:

1. `ridership_by_station_day`: suma por complejo y día. Sirve para el mapa y las series temporales.
2. `ridership_by_station_hourofweek_year`: suma por complejo, día de la semana y hora, separada por año. Es la base de los perfiles de 168 valores.
3. `ridership_by_month_borough_payment_fare`: base de la composición tarifaria.

Sobre la segunda vamos a normalizar cada perfil dividiéndolo por su propio total, para que las estaciones se agrupen por forma y no por tamaño.

Por qué esta data soporta el proyecto. El perfil de 168 valores requiere granularidad horaria, identificador de estación y cinco años continuos, y el dataset tiene las tres cosas. Las coordenadas por estación permiten llevar el resultado al mapa sin unir con otra fuente. Y `fare_class_category` da la desagregación por tipo de usuario que necesita la pregunta 7. Ninguna de nuestras preguntas depende de datos que no estén en la fuente.

5. Preguntas de dominio

Van de lo general a lo específico: primero el agregado, después la forma, después los grupos, después el cambio, después la geografía. Las preguntas 1 a 5 responden a la audiencia principal, porque terminan en qué estaciones cambiaron y dónde están. Las preguntas 6 y 7 responden a la audiencia secundaria, porque tratan de desigualdad y de composición de usuarios.

1. ¿Cómo evolucionó el volumen total de entradas entre 2020 y 2024, y en qué nivel se estabilizó?
2. ¿Cómo es el perfil de un día laborable frente al de un fin de semana, y cómo cambió esa forma en el período?
3. ¿Se pueden agrupar los complejos de estación según la forma de su perfil semanal? ¿Cuántos tipos salen y cómo se caracterizan?
4. ¿Qué estaciones cambiaron de tipo entre 2020 y 2024, y en qué dirección?
5. ¿Cómo se distribuyen geográficamente esos tipos y esos cambios? ¿Hay patrón por borough o por distancia a Manhattan?
6. ¿La recuperación fue pareja? ¿Qué estaciones siguen por debajo de su nivel inicial y cuáles lo superaron?
7. ¿Qué muestra la composición por clase tarifaria sobre quiénes sostuvieron la demanda en los años más bajos?

6. Factibilidad inicial

Desafíos técnicos esperados. El tamaño del archivo obliga a agregar del lado del servidor antes de bajar nada. Para el agrupamiento de perfiles hay que elegir el número de grupos y validarlo. Y en el navegador, más de 400 estaciones por 168 valores por varios años exige agregación previa y cuidado con el renderizado de los small multiples.

Alcance. El proyecto es realista para el semestre porque el pipeline se reduce a tres tablas agregadas que ya sabemos construir, y el script de adquisición está hecho desde la Semana 4. Las preguntas 1 a 5 son el núcleo y bastan para un proyecto completo; las preguntas 6 y 7 son extensión y las haremos solo si el tiempo alcanza. Si el agrupamiento resultara demasiado costoso, lo reemplazamos por dos índices directos, la razón pico/valle y la razón laborable/fin de semana, que responden las mismas preguntas con menos maquinaria.

División del trabajo. Renzo: pipeline de datos y agregaciones. Stewart: implementación en D3 y vistas enlazadas. José: narrativa, diseño visual y paper. Los tres participamos en la formulación de preguntas, la crítica de diseño y la presentación final.

Riesgos principales.

- Que `station_complex_id` no sea estable a lo largo del período. Para comparar una estación entre 2020 y 2024 el identificador tiene que ser el mismo; si hubo renombres o fusiones de complejos, las series se rompen. Es el riesgo más serio del proyecto.
- Que el agrupamiento de perfiles no produzca grupos interpretables.
- Que los límites de la API frenen la extracción de los agregados.
- Que el alcance quede demasiado grande para el semestre.